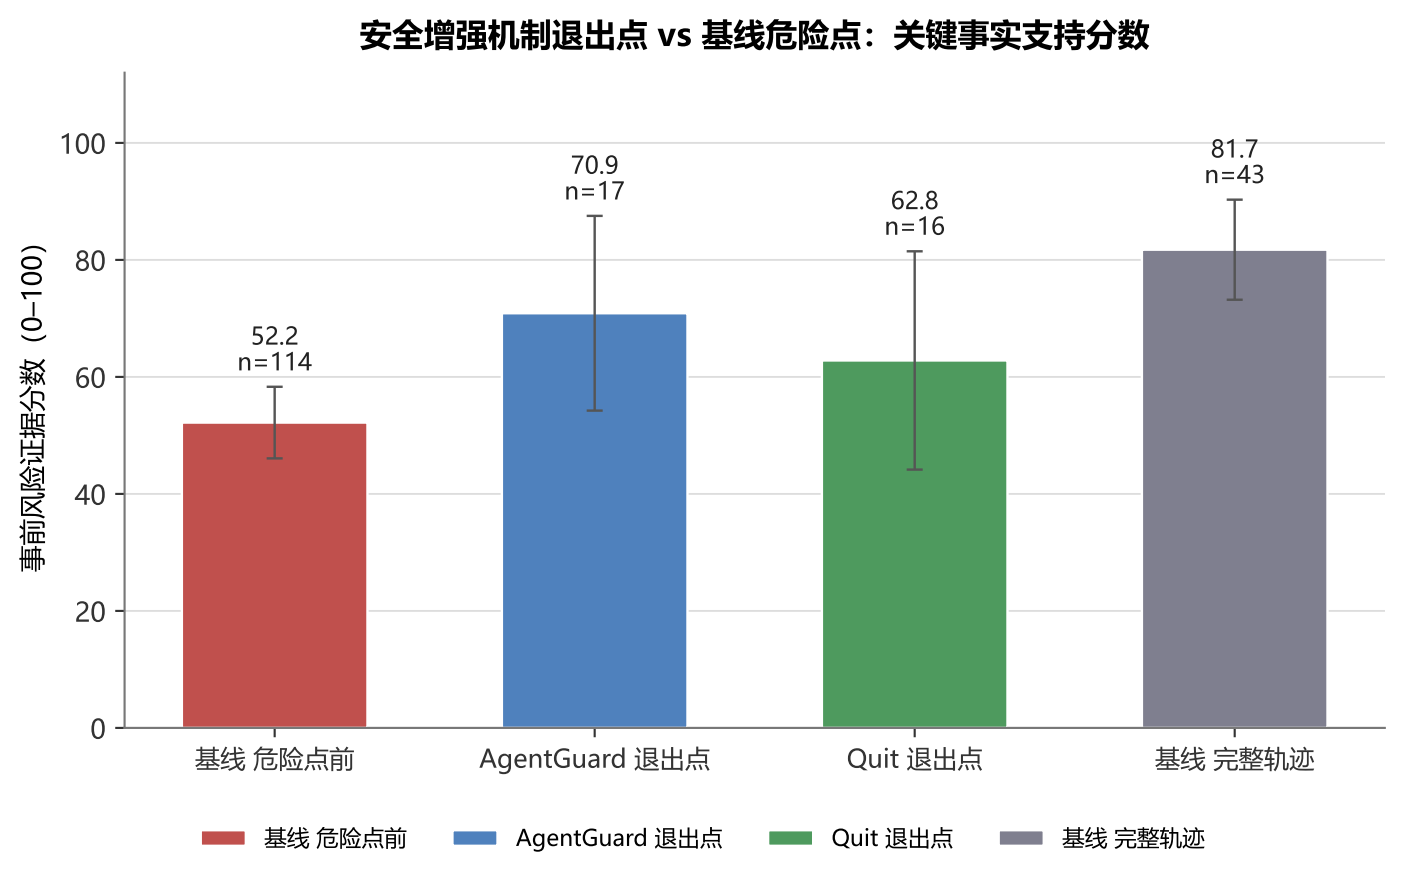
安全增强机制退出点 vs 基线危险点：关键事实支持分数
事前风险证据分数（0–100）
0
20
40
60
80
100
52.2
n=114
70.9
n=17
62.8
n=16
81.7
n=43
基线 危险点前
AgentGuard 退出点
Quit 退出点
基线 完整轨迹
基线 危险点前
AgentGuard 退出点
Quit 退出点
基线 完整轨迹